


Modellbildung mit Wahrscheinlichkeiten

Teil 1: Grundlagen der Wahrscheinlichkeitsrechnung





Wahrscheinlichkeitsrechnung

- Seien X und Y zwei diskrete **Zufallsvariablen**, die die Werte x_i , $i = 1, \dots, M$ und y_j , $j = 1, \dots, L$ annehmen können
 - *Beispiele:* Regen {ja, nein}, #verkaufte-Tickets {0,...,30000}, Pixel-Wert {0,...,255}, ...
 - Dabei gilt $0 \leq p(X) \leq 1$ und $0 \leq p(Y) \leq 1$ und für ein sicheres Ereignis gilt $p(X = x_i) = 1$
- $p(X = x_i, Y = y_j)$ nennt man die **gemeinsame Wahrscheinlichkeit** dafür, dass X den Wert x_i und Y den Wert y_j annimmt
- $p(Y = y_j)$ nennt man die **Randwahrscheinlichkeit** (engl.: marginal), d.h. die Wahrscheinlichkeit, dass ein Ereignis y_j eintritt, unabh. von anderen Ereignissen
- Betrachten wir nur die Realisierungen mit $X = x_i$, so nennt man den Anteil für den $Y = y_j$ gilt, die **bedingte Wahrscheinlichkeit** von $Y = y_j$ gegeben $X = x_i$, geschrieben $p(Y = y_j | X = x_i)$

Stochastische Unabhängigkeit

- Ein Ereignis X ist **stochastisch unabhängig** von Ereignis Y mit $p(Y) > 0$
genau dann wenn gilt: $p(X|Y) = p(X)$

z.B.: X =Würfel zeigt eine 6, Y =VfB-Spiel ist am Wochenende ausverkauft



- Ein Ereignis X ist **stochastisch unabhängig** von Ereignis Y mit $p(Y) > 0$
genau dann wenn gilt: $p(X, Y) = p(X) \cdot p(Y)$

Gesetze der Wahrscheinlichkeitsrechnung

Es gibt zwei grundlegende Gesetze der Wahrscheinlichkeitsrechnung:

$$p(X) = \sum_Y p(X, Y)$$

Summenregel (Marginalisierung)

$$p(X, Y) = p(Y|X)p(X)$$

Produktregel (Kettenregel)

Daraus folgt: **Bayes'sche Regel:**

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

Posterior = Likelihood * Prior / Evidenz

Likelihood: wie plausibel sind die Daten X gegeben Y

Bayes' Regel kann man aus der Produktregel und mit Hilfe der Symmetrieeigenschaft $p(X,Y)=p(Y,X)$ herleiten!

Beispiel: Medizinischer Test auf Krankheit

Bayes'sche Regel:

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

Posterior = Likelihood * Prior / Evidenz

Likelihood: wie plausibel sind die Daten X gegeben Y

Variablen:

G hat Grippe (ja/nein)

F hat Fieber (ja/nein)

Gegeben (aus Daten geschätzt oder durch Expertin vorgegeben):

- Prior:

$p(G = 1)$ (Prior-)Wahrscheinlichkeit, dass jemand Grippe hat, z.B. $p(G = 1) = 0.1$

- Likelihoods

$p(F = 1|G = 1)$ Wahrscheinlichkeit, dass jemand *mit Grippe* Fieber hat, z.B. $p(F = 1|G = 1) = 0.8$

$p(F = 1|G = 0)$ Wahrscheinlichkeit, dass jemand *ohne Grippe* Fieber hat, z.B. $p(F = pos|G = 0) = 0.1$

Beispiel: Medizinischer Test auf Krankheit

Bayes'sche Regel:

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

Posterior = Likelihood * Prior / Evidenz

Likelihood: wie plausibel sind die Daten X gegeben Y


$$p(G = 1|F = 1) = \frac{p(F = 1|G = 1)p(G = 1)}{p(F = 1)}$$

$$\begin{aligned} p(G = 1) &= 0.1 \\ p(F = 1|G = 1) &= 0.8 \\ p(F = 1|G = 0) &= 0.1 \end{aligned}$$

Gesucht: Posterior bei beobachtetem Fieber

- Evidenz (Wahrscheinlichkeit von Fieber, marginalisiert über Grippe):

$$p(F = 1) = p(F = 1|G = 1) \cdot p(G = 1) + p(F = 1|G = 0) \cdot p(G = 0)$$

Summenregel

$$= 0.8 \cdot 0.1 + 0.1 \cdot 0.9 = 0.17$$

- Posterior (Wahrscheinlichkeit, dass jemand tatsächlich krank ist, wenn der Test positiv ist):

$$p(G = 1|F = 1) = \frac{0.8 \cdot 0.1}{0.17} \approx 0.471$$


➔ Fieber erhöht die Grippe-Wahrscheinlichkeit von **10 %** (Prior) auf **~47 %** (Posterior)

Bayes vs. Frequentistische Sicht: Münzwurf

- *Münzwurf*: Was ist die Wahrsch.keit, dass eine gegebene Münze auf „Kopf“ landet?

- **Frequentistische Sicht:**

- Wirf die Münze viele Male
- Berechne $p(W = Kopf) \approx \frac{\#Kopf}{\#Münzwürfe}$



Frequentist: schwarz
Bayes: **gelb** (fair), **rot** (unfair zu Gunsten von Kopf)



- **Bayesianische Sicht:**

- Starte mit einer initialen Annahme, die auf Vorabwissen („prior knowledge“) beruht, z.B. gehe von einer fairen Münze aus und setze $p(W = Kopf) = 0.5$
- Verwende die gemachten Beobachtungen, um das Modell (Münze ist fair) – falls notwendig – zu aktualisieren

$$p(Fair = 1 | \dots, W_2, W_1) = \frac{p(W_N, \dots, W_2, W_1 | Fair = 1) \cdot p(Fair = 1)}{p(W_N, \dots, W_2, W_1)}$$

Erweiterte Bayes'sche Regel

$$p(Y|X_1, X_2) = \frac{p(X_1|Y, X_2)p(Y|X_2)}{p(X_1|X_2)}$$

↑
Erste Beobachtung, z.B. Fieber

↑
Zweite Beobachtung, z.B. Husten

z.B. $p(\text{Krankheit} | \text{Symptome})$

- Anwendung in der Diagnostik – was ist am wahrscheinlichsten?:

- $p(\text{"Krankheit a"} | \text{"Husten"}, \text{"Ausschlag"}, \text{"40 Grad Fieber"})$
- $p(\text{"Krankheit b"} | \text{"Husten"}, \text{"Ausschlag"}, \text{"40 Grad Fieber"})$
- $p(\text{"Krankheit c"} | \text{"Husten"}, \text{"Ausschlag"}, \text{"40 Grad Fieber"})$

➔ Bayes Klassifikator, Naiver Bayes Klassifikator (siehe Data Science VL)



Anwendungsbeispiel: Defektes Auto

Beobachtete Symptome (X):

ASA „Auto springt nicht an“
LIL „Licht leuchtet“
TAN „Tankanzeige > 0“

Diagnose (Y):

BAD „Batterie defekt“

- Gesucht ist die Wahrscheinlichkeit für eine defekte Batterie in Abhängigkeit aller beobachtbarer Ereignisse

$$p(BAD|ASA, LIL, TAN) = \frac{p(ASA, LIL, TAN|BAD) \cdot p(BAD)}{p(ASA, LIL, TAN)}$$

ASA	LIL	TAN	p
0	0	0	0.03
0	0	1	0.005
0	1	0	0.05
0	...		

2³ Einträge (zu erfassen / **Evidenz** aus Daten)

- 2 Zustände für jede der 3 Variablen

Schlussfolgern mit Bayes...

ASA „Auto springt nicht an“
 LIL „Licht leuchtet“
 TAN „Tankanzeige > 0“

Anwendungsbeispiel: Defektes Auto

- Lösung des Problems durch Bayes'sches Updating: „Eine Evidenz nach der anderen“
- Wir starten mit der Vorannahme/Anfangswahrscheinlichkeit $p(BAD)$ und updaten sequentiell:

Bayes:

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

• ASA: $p(BAD | ASA) = \frac{p(BAD) \cdot p(ASA | BAD)}{p(ASA)}$

Y=BAD, X=ASA

• LIL: $p(BAD | LIL, ASA) = \frac{p(BAD, LIL | ASA)}{p(LIL | ASA)} = \frac{p(BAD | ASA) \cdot p(LIL | ASA, BAD)}{p(LIL | ASA)}$

Y=BAD, X=LIL, Z=ASA X=BAD, Y=LIL, Z=ASA

$$= p(BAD) \cdot \frac{p(ASA | BAD)}{p(ASA)} \cdot \frac{p(LIL | ASA, BAD)}{p(LIL | ASA)}$$

Y=BAD, X=ASA

Produktregel:

$$p(X, Y) = p(Y|X)p(X)$$

$$\Leftrightarrow \frac{p(X, Y)}{p(X)} = p(Y|X)$$

Vereinfachung: Annahme, dass die Ereignisse ASA und LIL stochastisch unabhängig sind wenn man den Zustand der Batterie kennt (**Conditional Independence**)

$$= p(BAD) \cdot \frac{p(ASA | BAD)}{p(ASA)} \cdot \frac{p(LIL | BAD)}{p(LIL)}$$

$$\text{Allgemeiner: } p(X, Y|Z) = p(X|Z) \cdot p(Y|X, Z)$$

ASA „Auto springt nicht an“
 LIL „Licht leuchtet“
 TAN „Tankanzeige > 0“

Anwendungsbeispiel: Defektes Auto

- Schlussfolgern mit der Bayes-Regel: *BAD* „Batterie defekt“, von vorheriger Folie:

$$p(BAD | LIL, ASA) = p(BAD) \cdot \frac{p(ASA | BAD)}{p(ASA)} \cdot \frac{p(LIL | BAD)}{p(LIL)}$$

- Zweite Möglichkeit: *ALD* „Anlasser defekt“:


$$p(ALD | LIL, ASA) = p(ALD) \cdot \frac{p(ASA | ALD)}{p(ASA)} \cdot \frac{p(LIL | ALD)}{p(LIL)}$$

Wieder mit Vereinfachung:
Annahme, dass die Ereignisse ASA und LIL stochastisch unabhängig sind wenn man den Zustand des Anlassers kennt

- Relevant ist nur, **welche Diagnose wahrscheinlicher ist**, d.h. den (gleichen) Nenner kann man weglassen, es reicht, die anderen Terme zu berechnen und das Maximum zu bestimmen

Anwendungsbeispiel: Defektes Auto

- Graphische Darstellung als Bayes'sches Netz (*auch*: Belief Net):



Kausalitäten zwischen Zufallsvariablen ablesbar:

- „Wenn die Batterie defekt ist, dann springt das Auto (wahrscheinlich) nicht an“
- *BAD* ist eine *mögliche* Ursache für *ASA*


Modellbildung mit Wahrscheinlichkeiten

Teil 2: Graphische Modelle: Bayes Netze



Graphische Modelle

- Wir erweitern nun unseren Werkzeugkoffer, indem wir eine Repräsentation von Wahrscheinlichkeitsverteilungen als Graph einführen, genannt **Probabilistische Graphische Modelle** (PGMs), zu denen auch Bayes'sche Netze gehören
- Diese Repräsentation hat mehrere Vorteile:
 - Dient als Mittel zur **Visualisierung**
 - Erlaubt Einblicke in Modelleigenschaften, insbesondere in Hinblick auf die **bedingte Unabhängigkeit** von Variablen
 - Komplexe Berechnungen können in Form von **Graphmanipulationen** durchgeführt werden



- Jeder **Knoten** (A, B, C) repräsentiert eine (oder eine Gruppe von) Zufallsvariablen
- Jede **Kante** repräsentiert die wahrscheinlichkeitstheoretischen Abhängigkeiten zwischen diesen Variablen
- Wir betrachten zunächst **Bayes'sche Netze**, auch bekannt als **gerichtete Graphische Modelle** (Kanten haben eine Richtung)
- Im Gegensatz dazu verwenden **Markov Random Fields** ungerichtete Kanten

Bayes'sche Netze: Beispiel

$$\text{Produktregel: } p(X, Y) = p(Y|X)p(X)$$

- Gegeben: 3 (diskrete oder kontinuierliche) Zufallsvariablen A, B, C

$$p(A, B, C) = p(C|A, B)p(A, B) = p(C|A, B)p(B|A)p(A)$$

Produktregel


Produktregel

Konstruktion:

- Wähle **relevante** Wahrscheinlichkeitsvariablen
- Wähle eine **Ordnung** (d.h. Reihenfolge) für diese Variablen
- Solange Variablen übrig sind:
 - **Generiere** einen **Knoten** X für die nächste Variable
 - Setze $Eltern(X)$ minimal unter Einhaltung der definierten Abhängigkeiten, d.h. **füge Kanten ein** von $Eltern(X)$ (Ursachen) zu X (Wirkung)
 - **Definiere** die bedingten Wahrscheinlichkeiten für X (→ Faktor in der Zerlegung)
- Man sagt (gegeben das Beispiel): „ C hat die **Eltern** A und B “, „ C ist **Kind** von A und B “, „ C ist **bedingt abhängig** von A und B “



Die rechte Seite entspricht genau dem graphischen Modell der vorherigen Folie



Macht kausalen
Zusammenhang explizit:
Ursache A, Wirkung C

Frage: Ist das die einzige Darstellung? Wenn nicht, finden Sie eine andere!


Bayes'sche Netze

- Verallgemeinert gilt für K Variablen (mehrfache Anwendung der Produktregel):

$$p(X_1, \dots, X_K) = p(X_K | X_1, \dots, X_{K-1}) \cdot \dots \cdot p(X_2 | X_1) p(X_1)$$

...dieser Graph ist **vollständig verbunden** (jedes Knotenpaar teilt eine gerichtete Kante)

- Interessanter wird es, wenn das nicht der Fall ist, z.B. X_1 und X_2 in:



Faktorisieren Sie den links stehenden Graphen!




$$p(X_1, \dots, X_7) = p(X_1)p(X_2)p(X_3)p(X_4|X_1, X_2, X_3)p(X_5|X_1, X_3)p(X_6|X_4)p(X_7|X_4, X_5)$$

$$\text{Allgemein: } p(\mathbf{X}) = \prod_{k=1}^K p(X_k | \text{Eltern}(X_k))$$

$$\mathbf{X} = \{X_1, \dots, X_k\}$$

Achtung: Das funktioniert nur für azyklische Graphen!

Beispiel: Transformation im Automobilsektor (Förderung vs. Auswirkungen)



$$p(NAB = 1) = p(NAB = 1|S = 1) \cdot p(S = 1) + p(NAB = 1|S = 0) \cdot p(S = 0) = \dots = 0.39$$

$$p(NAB = 1|S = 1) = 0.65, \quad p(NAB = 1|S = 0) = 0.2$$

$$p(S = 1) = p(S = 1|U = 1, LB = 1) \cdot p(U = 1) \cdot p(LB = 1) + p(S = 1|U = 1, LB = 0) \cdot p(U = 1) \cdot p(LB = 0) + \dots =$$

$$0.8 \cdot 0.1 \cdot 0.6 + 0.65 \cdot 0.1 \cdot (1 - 0.6) + 0.5 \cdot (1 - 0.1) \cdot 0.6 + 0.2 \cdot (1 - 0.1) \cdot (1 - 0.6) = 0.416; \quad p(S = 0) = 1 - p(S = 1) = 0.584$$

Beispiel: Transformation im Automobilsektor (Förderung vs. Auswirkungen)

Was bedeutet das?

Wir können also, gegeben

- eine Reihe von **Priors für die Einflussfaktoren**
- den **bedingten Abhängigkeiten (CPTs)**,

eine **Posterior-Wahrscheinlichkeit** berechnen als Maß der Marktwirkung.

In diesem Fall war das $p(NAB = 1) = 0.39$, d.h. die Wahrscheinlichkeit für eine geringe Arbeitslosigkeit in diesem Transformationsszenario ist 39%.

Durch Verändern von z.B. $p(U = 1)$ kann man den Effekt von Markteingriffen simulieren.

Beispiel: Transformation im Automobilsektor (Förderung vs. Auswirkungen)

Übungsaufgabe:

- Wie wahrscheinlich ist es, dass *trotz* des Vorhandenseins von langlebigen Batterien und einer Umwelt/Kaufprämie wenig E-Autos verkauft werden, aber eine niedrige Arbeitslosigkeit herrscht?

Tipp: Gesucht wird also...

$$p(LB = 1, U = 1, S = 0, NAB = 1) \text{ (W'keit, dass dies zusammen eintrifft)}$$


Diese kann durch Faktorisierung aus dem Graphen berechnet werden.

Beispiel: Transformation im Automobilsektor (Förderung vs. Auswirkungen)

Bemerkungen:

- In realen Situationen oft **komplexere Modellierung** notwendig
 - In diesem Bayes'schen Netz sind alle Variablen Bernoulli Zufallsvariablen, da sie nur zwei mögliche Zustände annehmen können (0 oder 1), das Netz definiert also eine diskrete gemeinsame Verteilung über $\{0, 1\}^6$
 - *Im Allgemeinen:* Variablen können mehrere Werte annehmen (z.B. Höhe der Kaufprämie)
 - *Dafür nötig:* Komplexere Verteilungen (Binomial-, Normal-, geometrische Verteilung)
- Bayes'sche netze liefern **Wahrscheinlichkeiten, keine Absolutaussagen**
 - z.B. „zu 39% niedrige Arbeitslosigkeit“, „mit 85%iger Wahrscheinlichkeit ist Batterie defekt“
 - *Vorteil:* In der Realität herrscht häufig auch Unsicherheit
 - *Nachteil:* Ergibt noch keine Entscheidung (*Batterie tauschen oder nicht?*)

2. (klassisches) Beispiel: Judea Pearl



“The burglary alarm goes off very likely on burglary and occasionally on earthquakes. John and Mary are neighbors who agreed to call when the alarm goes off. Their reliability is different ...”

Alarm-Netzwerk


Einflussfaktoren	1. Einbruch
	2. Erdbeben
Auswirkungen	3. Alarm
	4. John ruft an
	5. Mary ruft an

2. (klassisches) Beispiel: Judea Pearl

Übungsaufgabe:

- Wie wahrscheinlich ist es, dass der Alarm losgeht, jedoch weder ein Einbruch noch ein Erdbeben vorliegt und sowohl John als auch Mary anrufen?

Tipp: Gesucht wird also $p(J, M, A, \bar{E}i, \bar{E}r)$



Inferenz in Bayes'schen Netzen

Wie wahrscheinlich ist eine Belegung einer/mehrerer Variablen, **geg. die beobachtete Evidenz?**

Ein Bayes'sches Netz erlaubt **verschiedene Arten von Inferenz:**

- **Diagnostische Inferenz:** Aus „*John ruft an*“ (Wirkung) schließen auf $p(Ei|J) = 0.016$ (Ursache)
(von Wirkung zu Ursache)

- **Prädiktive Inferenz:** Aus „*Einbruch*“ (Ursache) schließen auf
(von Ursache zu Wirkung, auch „kausale Inferenz“)
 $p(J|Ei) = 0.86, p(M|Ei) = 0.67$ (Wirkung)


Interkausale Inferenz: Aus „*Alarm*“ ergibt sich $p(Ei|A) = 0.367$

(Rückschluss zwischen mehreren möglichen Ursachen eines beobachteten Effekts)

Nimmt man „*Erdbeben*“ hinzu, verringert sich $p(Ei|A, Er) = 0.003$ obwohl „*Er*“ und „*Ei*“ unabhängig sind → „explaining away“

Prädiktive vs. Diagnostische Inferenz in Bayes'schen Netzen

Beobachtet



$$\begin{aligned}
 p(A) &= \sum_{ei, er \in \{0,1\}} p(A | ei, er) \cdot p(ei) \cdot p(er) \\
 &= 0.95 \cdot 0.001 \cdot 0.002 + 0.94 \cdot 0.001 \cdot (1 - 0.002) + \dots \\
 &\approx 0.0025
 \end{aligned}$$

Weiterhin: $p(J) = p(J | A)p(A) + p(J | \bar{A})p(\bar{A})$

$$\begin{aligned}
 p(A | \bar{J}, \bar{M}) &\stackrel{\text{Bayes}}{=} \frac{p(\bar{J}, \bar{M} | A) \cdot p(A)}{p(\bar{J}, \bar{M})} \stackrel{\text{u.a. geg. A}}{=} \frac{p(\bar{J} | A) \cdot p(\bar{M} | A) \cdot p(A)}{p(\bar{J}, \bar{M})} = \\
 &= \frac{(1 - 0.9) \cdot (1 - 0.7) \cdot p(A)}{(1 - 0.9) \cdot (1 - 0.7) \cdot p(A) + (1 - 0.05) \cdot (1 - 0.01) \cdot (1 - p(A))} \\
 &\approx 0.000085
 \end{aligned}$$

Prädiktive vs. Diagnostische Inferenz in Bayes'schen Netzen

Ohne Evidenz:

$$\begin{aligned} p(A) &= \sum_{ei, er \in \{0,1\}} p(A \mid ei, er) \cdot p(ei) \cdot p(er) \\ &= 0.95 \cdot 0.001 \cdot 0.002 + 0.94 \cdot 0.001 \cdot (1 - 0.002) + \dots \\ &\approx 0.0025 \end{aligned}$$


Mit Evidenz:

$$\begin{aligned} p(A \mid \bar{J}, \bar{M}) &= \frac{p(\bar{J}, \bar{M} \mid A) \cdot p(A)}{p(\bar{J}, \bar{M})} = \frac{p(\bar{J} \mid A) \cdot p(\bar{M} \mid A) \cdot p(A)}{p(\bar{J}, \bar{M})} \\ &= \frac{(1 - 0.9) \cdot (1 - 0.7) \cdot p(A)}{(1 - 0.9) \cdot (1 - 0.7) \cdot p(A) + (1 - 0.05) \cdot (1 - 0.01) \cdot (1 - p(A))} \\ &\approx 0.000085 \end{aligned}$$

D.h.: Wir erhalten eine deutliche gesunkene Alarmwahrscheinlichkeit durch die Evidenz (d.h. durch das Nicht-Anrufen von John und Mary) gegenüber dem Prior!

Prädiktive Inferenz in Bayes'schen Netzen

Beobachtet




Schluss von der Ursache (Einbruch) zur Wirkung (Alarm):

$$\begin{aligned}
 p(A | Ei) &= \sum_{er \in \{0,1\}} p(A | Ei, er) \cdot p(er) \\
 &= p(A | Ei, Er) \cdot p(Er) + p(A | Ei, \bar{E}r) \cdot p(\bar{E}r) \\
 &= 0.95 \cdot 0.002 + 0.94 \cdot 0.998 \approx 0.94
 \end{aligned}$$

Interkausale Inferenz in Bayes'schen Netzen

Beobachtet



Beide Wahrscheinlichkeiten (Einbruch, Erdbeben) steigen wegen des beobachteten Alarms an

„explaining away“ / Wegargumentieren:

Ist eine (mögliche) Ursache und Wirkung *bekannt* (Erdbeben), so ändert sich die Wahrscheinlichkeit für alternative Ursachen (Einbruch, wird kleiner)

Interkausale Inferenz in Bayes'schen Netzen - Detailrechnung

Berechnung (linke Seite der letzten Folie):

Brauchen wir für die Normierung, Alarm zwar beobachtet ($A=1$), aber wir wollen wissen, wie wahrscheinlich diese Beobachtung ist

$$p(A) = \sum_{ei, er \in \{0,1\}} p(A | ei, er) \cdot p(ei) \cdot p(er) \approx 0.002516442 \text{ (siehe ein paar Folien vorher)}$$

$$p(Ei|A) = \frac{(p(A | Ei, Er) \cdot p(Er) + p(A | Ei, \overline{Er}) \cdot p(\overline{Er})) \cdot p(Ei)}{p(A)} = \frac{(0.95 \cdot 0.002 + 0.94 \cdot 0.998) \cdot 0.001}{0.002516442} \approx 0.3736$$


$$p(Er|A) = \frac{(p(A | Ei, Er) \cdot p(Ei) + p(A | \overline{Ei}, Er) \cdot p(\overline{Ei})) \cdot p(Er)}{p(A)} = \frac{(0.95 \cdot 0.001 + 0.29 \cdot 0.999) \cdot 0.002}{0.002516442} \approx 0.2310$$

Berechnung (rechte Seite der letzten Folie):

$$p(Ei|A, Er) = \frac{p(A | Ei, Er) \cdot p(Ei)}{p(A | Ei, Er) \cdot p(Ei) + p(A | \overline{Ei}, Er) \cdot p(\overline{Ei})} = \frac{0.95 \cdot 0.001}{0.95 \cdot 0.001 + 0.29 \cdot 0.999} \approx 0.00327$$

Übungsaufgabe: Judea Pearls Alarmbeispiel

Wie schauen uns nun an, wie man das in **python** umsetzen kann mittels der **pgmpy library**



The screenshot shows a JupyterLab window titled "BayesNet-JudeaPearl" with a "Trusted" badge. The interface includes a menu bar (File, Edit, View, Run, Kernel, Settings, Help) and a toolbar with icons for file operations and execution. The main area contains a code editor with the following Python code:

```
[7]: from pgmpy.models import DiscreteBayesianNetwork
      from pgmpy.factors.discrete import TabularCPD
      from pgmpy.inference import VariableElimination

      # 1. Define structure of the Bayes Net with its edges from parents to children
      model = DiscreteBayesianNetwork([
          ('Einbruch', 'Alarm'),
          ('Erdbeben', 'Alarm'),
          ('Alarm', 'JohnRuftAn'),
          ('Alarm', 'MaryRuftAn')
      ])

      # 2. Define probabilities
      # Unconditioned probabilities (Priors)
      # ...variable_card is the cardinality, i.e. the number of states the variable can have
      # ...CPD: conditional probability distribution
      cpd_einbruch = TabularCPD(variable='Einbruch', variable_card=2,
                               values=[[0.999], [0.001]]) # order is [False, True]
      cpd_erdbeben = TabularCPD(variable='Erdbeben', variable_card=2,
                                values=[[0.998], [0.002]])

      # Alarm | Einbruch, Erdbeben
      cpd_alarm = TabularCPD(
          variable='Alarm', variable_card=2,
          values=[
```

Zweite Übungsaufgabe: Grippe

```
Im Rahmen eines medizinischen Frühwarnsystems soll mithilfe eines Bayes'schen Netzes modelliert werden, wie wahrscheinlich es ist, dass eine Person an Grippe erkrankt ist, basierend auf beobachteten Symptomen (Fieber und Husten) sowie dem Verhalten (z. B. ob sie einen Arzt aufsucht).

Das Ziel ist es, das Netz zu analysieren und mithilfe von bedingten Wahrscheinlichkeiten diagnostische und kausale Inferenz durchzuführen.

Variable      Bedeutung      Zustände (Werte)
#-----#
G(rippe)      Person hat Grippe    0 = nein, 1 = ja
F(ieber)      Person hat Fieber    0 = nein, 1 = ja
H(usten)      Person hat Husten    0 = nein, 1 = ja
A(rzt)        Person geht zum Arzt 0 = nein, 1 = ja

Die Abhängigkeiten sind wie folgt definiert:
* Grippe beeinflusst Fieber und Husten
* Fieber und Husten beeinflussen gemeinsam die Wahrscheinlichkeit für BesuchArzt

Graphische Darstellung:
```

Bedingte Unabhängigkeit (Conditional Independence)

- Betrachten wir nochmal ein Beispiel mit 3 Variablen. Es gelte:

$$p(A|B,C) = p(A|C)$$

d.h. die *bedingte Wahrscheinlichkeit* von A hängt **nicht** von B ab

Dann sagt man:

A ist **bedingt unabhängig** von B gegeben C ,
manchmal geschrieben $A \perp B | C$

Beispiel:

A : Person trägt **Regenschirm**

B : **Straße** ist **nass**

C : Es **regnet**



- Ob jemand einen **Regenschirm** bei sich hat (A), hängt davon ab, ob es **regnet** (C)
- Ob die **Straße nass** ist (B), hängt auch davon ab, ob es **regnet** (C)
- Aber:* Wenn man weiß, **dass es regnet** (C), dann ist die Info, ob die **Straße nass** ist (B), nicht mehr hilfreich, um zu beurteilen, ob jemand einen **Regenschirm trägt** (A)

Bedingte Unabhängigkeit (Conditional Independence)


- Für die gemeinsame Verteilung von A und B gegeben C folgt

$$p(A, B|C) = p(A|B, C)p(B|C) = p(A|C)p(B|C)$$

Produktregel

Bedingte Unabhängigkeit

- Diesen Zusammenhang kann man wieder als graphisches Modell darstellen (Hinweis: Wir faktorisieren hier die bedingte W'keit):
- Aber:* Warum das Ganze? Das kann hilfreich sein...
 - Um die Struktur eines graphischen Modells zu vereinfachen
 - Um die Rechenkomplexität zu verringern



Beispielgraph 1: Verzweigung

- Es gilt: $p(A, B, C) = p(A|C)p(B|C)p(C)$
- Wir nehmen an, dass **keine** der 3 Variablen **beobachtet** wurde. Durch Marginalisieren beider Seiten der Gleichung bzgl. C erhalten wir Aufschluss bzgl. der Unabhängigkeit von A und B :


$$p(A, B) = \sum_C p(A|C)p(B|C)p(C)$$

- Üblicherweise faktorisiert die rechte Seite nicht in $p(A)p(B)$, d.h. $A \not\perp B | \emptyset$ *
- Nun nehmen wir an, dass **C beobachtet** wurde, es folgt


$$p(A, B|C) = \frac{p(A, B, C)}{p(C)} = p(A|C)p(B|C)$$

Produktregel wegen oben

und damit $A \perp B | C$



Was wir beobachtet haben




* Sprich: A ist nicht bedingt unabhängig von B gegeben die leere Menge

Beispielgraph 1: Verzweigung

Beispiel:

- Das Wetterbeispiel von eben: A : Person trägt **Regenschirm**, B : **Straße** ist **nass**, C : Es **regnet**



Graphische Interpretation:

- Wir betrachten den **Pfad** von Knoten A nach B
- Der Knoten C wird in Bezug auf diesen Pfad als „**Tail-to-Tail**“ bezeichnet, da er mit den Ausgangsseiten der beiden Pfeile verbunden ist
- Die Existenz eines solchen Pfades bedeutet, dass die beiden Knoten **abhängig** voneinander sind
- Wenn wir auf den Knoten C bedingen/konditionieren, dann „**blockiert**“ dieser konditionierte Knoten den Pfad und dadurch werden A und B **bedingt unabhängig**


Beispielgraph 2: Kette

$$\begin{aligned} * \quad p(X) &= \sum_Y p(X, Y) \\ p(X, Y) &= p(Y|X)p(X) \end{aligned}$$

Summenregel (Marginalisierung)

Produktregel (Kettenregel)


- Es gilt: $p(A, B, C) = p(A)p(C|A)p(B|C)$
- Wir nehmen wieder an, dass **keine** der 3 Variablen **beobachtet** wurde. Durch Marginalisieren beider Seiten der Gleichung bzgl. C erhalten wir wieder Aufschluss bzgl. der Unabhängigkeit von A und B :



$$p(A, B) = p(A) \sum_C p(C|A)p(B|C) \stackrel{*}{=} p(A)p(B|A)$$

- Üblicherweise faktorisiert die rechte Seite nicht in $p(A)p(B)$, d.h. $A \not\perp B | \emptyset$
- Nun nehmen wir wieder an, dass **C beobachtet** wurde, es folgt


$$p(A, B|C) = \frac{p(A, B, C)}{p(C)} = \frac{p(A)p(C|A)p(B|C)}{p(C)} = p(A|C)p(B|C)$$



und damit $A \perp B | C$

$$\begin{aligned} p(A)p(C|A) &= p(A, C) \\ p(A, C)/p(C) &= p(A|C) \end{aligned}$$

Beispielgraph 2: Kette



Beispiel:

- A : Person **lernt viel** (ja/nein), B : hat **Prüfung bestanden** (ja/nein), C : hat **gutes Verständnis** (ja/nein)
- Ohne Beobachtung: A und B abhängig, mit Beobachtung von C nicht (nur C relevant, ob jemand besteht)

Graphische Interpretation:

- Wir betrachten wieder den **Pfad** von Knoten A nach B
- Der Knoten C wird in Bezug auf diesen Pfad als „**Head-to-Tail**“ bezeichnet
- Auch hier gilt: Die Existenz eines solchen Pfades bedeutet, dass die beiden Knoten **abhängig** voneinander sind
- Wenn wir auf den Knoten C bedingen/konditionieren, dann „**blockiert**“ dieser konditionierte Knoten wieder den Pfad und dadurch werden A und B wieder **bedingt unabhängig**

Beispielgraph 3: Zusammenführung

- Es gilt: $p(A, B, C) = p(A)p(B)p(C|A, B)$
- Wir nehmen an, dass **keine** der 3 Variablen **beobachtet** wurde. Durch Marginalisieren beider Seiten der Gleichung bzgl. C erhalten wir Aufschluss bzgl. der Unabhängigkeit von A und B :



$$p(A, B) = p(A)p(B)$$

- In diesem Fall sind A und B also unabhängig, auch wenn keine Variablen beobachtet wurden, d.h. $A \perp B | \emptyset$
- Nun nehmen wir an, dass **C beobachtet** wurde, es folgt

$$p(A, B|C) = \frac{p(A, B, C)}{p(C)} = \frac{p(A)p(B)p(C|A, B)}{p(C)} \underset{\text{Bayes}}{=} p(A|C)p(B|C) \frac{p(C)p(C|A, B)}{p(C|A)p(C|B)}$$

was i.A. nicht zu $p(A|C)p(B|C)$ faktorisiert und damit $A \not\perp B | C$

Hier haben wir also ein gegensätzliches Verhalten!




Beispielgraph 3: Zusammenführung

Beispiel:

- A : **Einbruch** (ja/nein), B : **Erdbeben** (ja/nein), C : **Alarm** geht los, wenn Einbruch oder Erbeben
- Gegeben C werden A und B abhängig ($\Rightarrow$ **explaining away**)

Graphische Interpretation:


- Wir betrachten wieder den **Pfad** von Knoten A nach B
- Der Knoten C wird in Bezug auf diesen Pfad als „**Head-to-Head**“ bezeichnet, da er mit den Endseiten der beiden Pfeile verbunden ist
- Falls C **nicht beobachtet** wird, blockiert dieser Knoten den Pfad und die beiden Variablen sind **unabhängig**
- Wenn wir auf den Knoten C bedingen/konditionieren (da wir den Knoten beobachten), dann „**ent-blockiert**“ dieser Knoten den Pfad und dadurch werden A und B **abhängig**



Pfad von A nach B ist **nicht** blockiert durch F , denn tail-to-tail und nicht beobachtet

D-Separation (J. Pearl 1988)

- Wir betrachten einen gerichteten Graphen mit drei *beliebig* gewählten, *disjunkten Mengen* von Knoten A , B , C (Mengen hier **fett** geschrieben, $A \neq A$), deren Vereinigung kleiner oder gleich der Menge aller Knoten sei
- Wir untersuchen nun, ob die Aussage $A \perp B \mid C$ zur bedingten Unabhängigkeit gültig ist, wozu wir *jeden* möglichen *ungerichteten* Pfad von einem beliebigen Knoten in A zu einem beliebigen Knoten in B betrachten
- Ein solcher Pfad heißt „blockiert“ wenn er einen Knoten enthält, so dass
 - Die Pfeile auf dem Pfad sich „head-to-tail“ oder „tail-to-tail“ in diesem Knoten treffen und der Knoten zur Menge C (auf die bedingt wird) gehört
 - Die Pfeile sich „head-to-head“ in einem Knoten treffen, wobei weder der Knoten noch irgendeiner seiner Nachfolger zur Menge C gehört
- **Satz:** Falls *alle* Pfade blockiert sind, dann heißt A *D-separiert* von B durch C und es gilt $A \perp B \mid C$




Pfad von A nach B ist **nicht** blockiert durch E , obwohl head-to-head, denn E hat Nachfolger C auf den bedingt wird (d.h. der beobachtet wurde)

→ Es folgt $A \not\perp B \mid C$

D-Separation (J. Pearl 1988)


- Wir betrachten einen gerichteten Graphen mit drei *beliebig* gewählten, *disjunkten Mengen* von Knoten **A**, **B**, **C** (Mengen hier **fett** geschrieben, $A \neq A$), deren Vereinigung kleiner oder gleich der Menge aller Knoten sei
- Wir untersuchen nun, ob die Aussage $A \perp B \mid C$ zur bedingten Unabhängigkeit gültig ist, wozu wir *jeden* möglichen *ungerichteten* Pfad von einem beliebigen Knoten in **A** zu einem beliebigen Knoten in **B** betrachten
- Ein solcher Pfad heißt „blockiert“ wenn er einen Knoten enthält, so dass
 - Die Pfeile auf dem Pfad sich „head-to-tail“ oder „tail-to-tail“ in diesem Knoten treffen und der Knoten zur Menge **C** (auf die bedingt wird) gehört
 - Die Pfeile sich „head-to-head“ in einem Knoten treffen, wobei weder der Knoten noch irgendeiner seiner Nachfolger zur Menge **C** gehört
- **Satz:** Falls *alle* Pfade blockiert sind, dann heißt **A** *D-separiert* von **B** durch **C** und es gilt $A \perp B \mid C$

Pfad von **A** nach **B** ist blockiert durch **F**,
denn tail-to-tail und beobachtet



Pfad von **A** nach **B** ist blockiert
durch **E**, denn head-to-head,
und weder **E** noch Nachfolger
C beobachtet

Warum das Ganze?



- Aus einem gegebenen gerichteten Graphen können wir also ohne Rechnung ablesen:
 - Eine **spezifische Zerlegung einer gemeinsamen Wahrscheinlichkeitsverteilung** in ein Produkt bedingter Wahrscheinlichkeiten
 - Eine **Menge bedingter Unabhängigkeitsaussagen**
- D-Separation Satz zeigt die enge Verknüpfung dieser Eigenschaften auf (Faktorisierung $\leftrightarrow$ Unabhängigkeit)
- D-Separation
 - sagt uns, welche Abhängigkeiten nicht existieren, d.h. wo wir **Speicher und Rechenaufwand sparen** können (z.B., nicht auf irrelevante Variablen bedingen)
 - Welche Informationen durch Beobachtungen weitergegeben werden und wie sich Wahrscheinlichkeiten ändern, wenn wir neue Daten erhalten
 - Erlaubt **Modellüberprüfung**; z.B. Finden von Modellierungsfehler, wenn etwa zwei Variablen in den Daten bedingt abhängig sind, der Graph laut D-Separation aber sagt, sie seien unabhängig

Zu berechnen: $p(\text{Husten} \mid \text{Rauchen} = \text{Ja})$

Beobachtung: Atemnot ist *D-separiert* von Husten gegeben Rauchen, d.h. es gilt $\text{Atemnot} \perp \text{Husten} \mid \text{Rauchen}$

Atemnot muss also nicht berücksichtigt werden:

Im pgmpy Code heisst das:

```
result_dsep =  
infer.query(variables=['Husten'],  
evidence={'Rauchen': 1})
```

statt

```
result_nodsep =  
infer.query(variables=['Husten'],  
evidence={'Rauchen': 1, 'Atemnot': 0})
```

(zwingt pgmpy zur Berücksichtigung, langsamer!)

Kontrollfragen

Notieren Sie zu den folgenden Fragen kurz Ihre Antwort. Wenn alle Fragen bearbeitet sind, diskutieren Sie die Lösungen kurz mit dem Nachbarn/der Nachbarin:

- Wie ist ein *Bayes'sches Netz* definiert?
- Was versteht man unter Inferenz in Bayes'schen Netzen und welche *Inferenzformen* gibt es?
- Übersetzen Sie in „verständliche“ menschliche Sprache: „*A D-separiert Y und Z*“!

D-Separation: Aufgabe (1)

Gegeben sei ein gerichteter Graph $G = (V, E)$ mit $V = \{A, B, C, D\}$ und $E = \{(A, B), (A, C), (C, D), (B, D)\}$

- a. Zeichnen Sie den zugehörigen Graphen!
- b. Geben Sie die Mengen X an, welche zwei davon disjunkte Mengen $X1, X2$ aus dem Graphen D-separieren


Modellbildung mit Wahrscheinlichkeiten

Teil 3: Kurzer Blick auf Markov Random Fields



Markov Random Fields (auch: Markov Netz)




- Äquivalent zu Bayes Netzen, aber für ungerichtete Graphen
- Typische Anwendung: Entrauschen von Bildern



Bayes


vs.

Markov



Morale Graphen


- Ein **moralischer Graph** ist ein ungerichteter Graph, der aus einem gerichteten azyklischen Graphen (DAG) entsteht, indem man:
 - Alle Eltern eines gemeinsamen Kindes miteinander verbindet (also „verheiratet“ – daher der Name „moralisch“)
 - Alle gerichteten Kanten entfernt und durch ungerichtete Kanten ersetzt




- im moralischen Graphen sind *A* und *B* verbunden, weil durch das gemeinsame Kind *C* ein potenzieller Zusammenhang entsteht, wenn man z.B. *C* beobachtet
- Das ist hilfreich, um z.B. bedingte Abhängigkeiten wie „*explaining away*“ korrekt darzustellen

Beispiel: Klassifikation von Massenspektrometrischen Bildern

Piece of tissue for MSI analysis




Imaging mass spectrometry




chemical staining

Stained tissue sample





necrotic tumor
viable tumor
glass




→ Data cube with 2 spatial, 1 spectral dimension

Massenspektrometrisches Bild eines Rattengehirns

- Zerlegung in parallele Scheiben
- Chemisches Anfärben und Labeln jeder zweiten Schicht, fünf Klassen:
necrotic tumor, **viable tumor**, **interface region**, **gelatin**, **glass**
- Verbliebene Schichten für massenspektr. Analyse
- Idee:
 - Trainieren eines Klassifikators auf einer Schicht
 - Klassifikation einer anderen Schicht
 - Trainingsbeispiele: gelabelte Pixel der Trainingsbsp.
 - Merkmale: 116 ausgewählte Kanäle
→ 116-dimensionaler Merkmalsraum
 $p=116$




Massenspektrometrisches Bild eines Rattengehirns





Leave-One-Out Experiment: Training mit 5 von 6 Schichten, Testen des Klassifikators auf der verbliebenen Schicht

Merkmale: ausgewählte m/z Kanäle der massenspektrometrischen Bilder



Massenspektrometrisches Bild eines Rattengehirns



- Idee Markov Random Field:
 - Klassenwahrscheinlichkeiten via pixel-weisem Klassifikator (Random Forest) (lokale Evidenz, „single-site-potential“)
 - Homogenität / Rauschminderung via Term, der die gleiche Klassifikation von Nachbarpixeln forciert („pair potential“)



Zusammenfassung

- **Wiederholung**
 - Bayes'sche Statistik
- **Graphische Modelle: Bayes-Netze**
 - Konstruktion
 - Inferenz
 - Bedingte Unabhängigkeit und D-Separation
- **Kurzer Einblick: Markov Random Fields**
- **Anwendungen**

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$



Python (pip install pgmpy) 1/2

```
from pgmpy.models import DiscreteBayesianNetwork

from pgmpy.factors.discrete import TabularCPD

from pgmpy.inference import VariableElimination

# 1. Define structure of the Bayes Net with its edges from parents to children
model = DiscreteBayesianNetwork([

    ('Einbruch', 'Alarm'), ('Erdbeben', 'Alarm'),

    ('Alarm', 'JohnRuftAn'), ('Alarm', 'MaryRuftAn')

])

# 2. Define probabilities

# Unconditioned probabilities (Priors)

# ...variable_card is the cardinality, i.e. the number of poss. var. states
# ...CPD: conditional probability distribution
cpd_einbruch = TabularCPD(variable='Einbruch', variable_card=2,

                           values=[[0.999], [0.001]]) # [False, True]

cpd_erdbeben = TabularCPD(variable='Erdbeben', variable_card=2,

                           values=[[0.998], [0.002]])

# Alarm | Einbruch, Erdbeben
cpd_alarm = TabularCPD(

    variable='Alarm', variable_card=2,

    values=[

        [0.999, 0.71, 0.06, 0.05], # Alarm = False

        [0.001, 0.29, 0.94, 0.95]  # Alarm = True

    ],

    evidence=['Einbruch', 'Erdbeben'],

    evidence_card=[2, 2]

)

# JohnRuftAn | Alarm
cpd_john = TabularCPD(variable='JohnRuftAn', variable_card=2,

                       values=[[0.95, 0.1], # JohnRuftAn = False

                               [0.05, 0.9]], # JohnRuftAn = True

                       evidence=['Alarm'], evidence_card=[2])

# MaryRuftAn | Alarm
cpd_mary = TabularCPD(variable='MaryRuftAn', variable_card=2,

                       values=[[0.99, 0.3], # MaryRuftAn = False

                               [0.01, 0.7]], # MaryRuftAn = True

                       evidence=['Alarm'], evidence_card=[2])

# add CPDs to model
model.add_cpds(cpd_einbruch, cpd_erdbeben, cpd_alarm, cpd_john, cpd_mary)
```

Python (pip install pgmpy) 2/2

```
# Check model consistency (e.g., all variables have
# CPDs, dimensions match, CPDs are normalized)
assert model.check_model()
```

```
# 3. Initialize inference engine
inference = VariableElimination(model)
```

```
# 4. Compute and print marginals
alarm = inference.query(variables=['Alarm'])
print(alarm)

john = inference.query(variables=['JohnRuftAn'])
print(john)

mary = inference.query(variables=['MaryRuftAn'])
print(mary)
```

```
# === Diagnostic Inference ===
# Given: JohnRuftAn = False, MaryRuftAn = False
# Tbd: Probability for Einbruch
```

```
alarm = inference.query(variables=['Alarm'],
                          evidence={'JohnRuftAn': 0, 'MaryRuftAn': 0})

print(alarm)

diagnosis = inference.query(variables=['Einbruch'],
                             evidence={'JohnRuftAn': 0, 'MaryRuftAn': 0})

print("\nDiagnostische Inferenz (p(Einbruch | JohnRuftAn=False,
MaryRuftAn=False)):")

print(diagnosis)
```

```
# === Causal Inference ===
# Given: Einbruch = True
# Tbd: Probability for John calling

alarm = inference.query(variables=['Alarm'],
                          evidence={'Einbruch': 1})

print(alarm)

causal = inference.query(variables=['JohnRuftAn'],
                           evidence={'Einbruch': 1})

print("\nKausale Inferenz (p(JohnRuftAn | Einbruch)):")

print(causal)
```